

基础数理统计 2023 Spring				
Discrete dist.	pmf	mean	variance	mgf/moment
Discrete Uniform( $n$ )	$\frac{1}{n}$	$\frac{n+1}{2}$	$\frac{n^2-1}{12}$	$\frac{e^t(1-e^{nt})}{n(1-e^t)} = \frac{1}{n} \sum e^{it}$
Bernoulli( $p$ )	$p^x(1-p)^{1-x}$	$p$	$p(1-p)$	$(1-p)+pe^t$
Binomial( $n, p$ )	$\binom{n}{x}p^x(1-p)^{n-x}$	$np$	$np(1-p)$	$((1-p)+pe^t)^n$
Geometric( $p$ )	$(1-p)^{x-1}p$	$\frac{1}{p}$	$\frac{1-p}{p^2}$	$\frac{pe^t}{1-(1-p)e^t}$
Poisson( $\lambda$ )	$\frac{\lambda^x}{x!}e^{-\lambda}$	$\lambda$	$\lambda$	$e^{\lambda(e^t-1)}$
Beta-binomial ( $n, \alpha, \beta$ )	$\binom{n}{x} \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} \cdot \frac{\Gamma(x+\alpha)\Gamma(n-x+\beta)}{\Gamma(n+\alpha+\beta)}$	$\frac{n\alpha}{\alpha+\beta}$	$\frac{n\alpha\beta}{(\alpha+\beta)^2}$	If $X P$ is Binomial( $n, P$ ), and $P$ is Beta( $\alpha, \beta$ ), then $X$ is Beta-binomial( $n, \alpha, \beta$ ).

$$\begin{aligned}(uv)' &= uv' + u'v & (f(g(x)))' &= f'(g(x))g'(x) \\ (\frac{u}{v})' &= \frac{u'v-uv'}{v^2} & (a^x)' &= (\ln a)a^x \\ \int uv' \, \mathrm{d}x &= uv - \int u'v \, \mathrm{d}x\end{aligned}$$

#### 1.概率

条件概率  $P(A|B) = P(AB)/P(B)$

全概率  $P(B) = \sum_i P(B|A_i)P(A_i)$

贝叶斯  $P(A_i|B) = \frac{P(B|A_i)P(A_i)}{\sum_j P(B|A_j)P(A_j)}$

**例**蓝眼 1/4. 对于三个孩子的家庭, 如果至少有一个孩子是蓝眼睛 (A), 至少有两个蓝眼睛 (B) 的概率为  $P(B|A) = P(AB)/P(A) = P(B)/P(A) = 10/37$ .

**例** $p_{1...5} = 0, \frac{1}{4}, \frac{1}{2}, \frac{3}{4}, 1$  代表第  $i$  枚硬币出现正面的概率. 随机选取一枚硬币, 投掷直到出现正面. 求  $P(C_i \mid B_4)$ ,  $B_4$  表示第 4 次首次出现正面. 由贝叶斯,  $P(C_i|B_4) = \frac{P(B_4|C_i)P(C_i)}{\sum_{i \in [5]} P(B_4|C_i)P(C_i)} = \frac{P(B_4|C_i)}{\sum_{i \in [5]} P(B_4|C_i)}$ .

#### 2.随机变量

随机变量  $X: \Omega \mapsto \mathbb{R}$  对每个样本赋予实值.

CDF  $F_X(x) = P(X \leq x)$

PDF 1:  $f_X(x) \geq 0$ , 2:  $\int_{-\infty}^{+\infty} f_X(x) \, \mathrm{d}x = 1$ , 3:

$P(a < X < b) = \int_a^b f_X(x) \, \mathrm{d}x$ .

$F^{-1}(q) = \inf\{x : F(x) > q\}$ ,  $(\max x : f(x) \leq q)$

Poisson 分布: 平均 5 分钟 10 人到店, 问等待第一个顾客两分钟以上的概率. 两分钟实际到店人数  $X$  服从参数为  $\lambda = 4$  的 Poisson 分布,  $P(T > 2) = P(X = 0) = e^{-4}$ . 推广, 等待时间  $F(t) = 1 - e^{-\lambda t}$ ,  $f(t) = F'(t) = \lambda e^{-\lambda t}$ , 为指数分布,  $t \in [0, \infty)$ .

二维正态分布:  $f(x, y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \cdot \exp\left(-\frac{1}{2(1-\rho^2)}\left[\frac{(x-\mu_1)^2}{\sigma_1^2} + \frac{(y-\mu_2)^2}{\sigma_2^2} - \frac{2\rho(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2}\right]\right)$

边际分布:  $f_X(x) = \int_{-\infty}^{+\infty} f(x, y) \, \mathrm{d}y$

独立定义  $P(X \in A, Y \in B) = P(X \in A)P(Y \in B)$ ,  $f_{X,Y}(x, y) = f_X(x)f_Y(y)$ , 独立 iff  $\forall x, y, f(x, y) = r(x)g(y)$ ,  $f_X(x) = r(x)/\int_{-\infty}^{\infty} r(x) \, \mathrm{d}x$

条件分布  $f_{X|Y}(x|y) = \frac{P(X=x, Y=y)}{P(Y=y)} = \frac{f_{X,Y}(x, y)}{f_Y(y)}$

$$\begin{aligned}(\arcsin x)' &= \frac{1}{\sqrt{1-x^2}} & (\arctan x)' &= \frac{1}{1+x^2} \\ (\arccos x)' &= -\frac{1}{\sqrt{1-x^2}}\end{aligned}$$

多项分布:  $P(\dots, X_k = n_k) = \frac{n!}{n_1! \dots n_k!} p_1^{n_1} \dots p_k^{n_k}$   
多元正态分布:  $f(x_1, \dots, x_n) = \frac{1}{(2\pi)^{n/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(x - \mu)^T \Sigma^{-1}(x - \mu)\right)$

随机变量的函数: 对于随机变量  $X$  考虑函数形式  $r(x)$ , 计算  $Y = r(X)$  的分布: 对每个  $y$  求集合  $A_y = \{x : r(x) \leq y\}$ ; 求 CDF:  $F_r(X)(y) = P(r(X) \leq y) = P(X \in A_y) = \int_{A_y} f_X(x) \, \mathrm{d}x$ ; 求 PDF:  $f_Y(y) = F_Y'(y)$ . 当  $r$  单调时,  $r$

的反函数为  $s = r^{-1}$ , 有  $f_Y(y) = f_X(s(y)) \left|\frac{\mathrm{d}s(y)}{\mathrm{d}y}\right|$ .

**例**  $f_X(x) = e^{-x}$  ( $x > 0$ ),  $F_X(x) = \int_0^x f_X(s) \, \mathrm{d}s = 1 - e^{-x}$ . 令  $Y = r(X) = \log X$ ,  $A_y = \{x : x \leq e^y\}$ ,  $F_Y(y) = P(X \leq e^y) = F_X(e^y) = 1 - e^{-e^y}$ ,  $f_Y(y) = F_Y'(y) = e^y e^{-e^y}$ .

**例**令  $X, Y \sim \text{Uniform}(0, 1)$  且独立,  $X - Y$  PDF.  $Z = X - Y$ ,  $F_Z(z) =$

$$f_{x+y\leq z}\cdots=\begin{cases}0,z\leq-1\\ \frac{(1+z)^2}{2},-1< z < 0\\ 1-\frac{(1-z)^2}{2},0\leq z < 1\\ 1,z\geq 1\end{cases}\qquad \begin{cases}f_Z(z)=\\ 1+z, \quad -1 < z < 0\\ 1-z, \quad 0\leq z < 1\\ 0, \quad \text{otherwise}\end{cases}$$

#### 3.期望

$\mu_X = E(X) = \int x \, \mathrm{d}F(x) < \infty$ , 称期望存在.

懒惰统计学家法则  $E(r(X)) = \int r(x) \, \mathrm{d}F_X(x)$ .

$k$  阶矩  $E(X^k)$ , 中心矩  $E((X - \mu)^k)$ .  
 $\sigma^2 = V(X) = E((X - \mu)^2) = E(X^2) - E(X)^2$   
样本  $\bar{X} = 1/n \sum X_i$ ,  $S_n^2 = 1/(n-1) \sum (X_i - \bar{X})^2$   
定理:  $E(\bar{X}_n) = \mu$ ,  $V(\bar{X}_n) = \sigma^2/n$ ,  $E(S_n^2) = \sigma^2$ .  
 $\text{Cov}(X, Y) = E((X - \mu_X)(Y - \mu_Y)) = E(XY) - E(X)E(Y)$ , 不相关:  $\text{Cov}(X_i, X_j) = 0$ , 此时两者方差可加, 但不代表独立 (**例**  $X = U(-1, 1)$ ,  $Y = |X|$ )  
矩母函数  $M_X(t) = E(e^{tX})$ . 如果  $Y = aX + b$ , 则  $M_Y(t) = e^{bt} M_X(at)$ . 意义:  $E(X^n) = M_X^{(n)}(0)$ .

**例**  $X \sim \text{Exp}(\lambda)$ ,  $E(X) = M_X'(0) = \frac{\lambda}{(\lambda-t)^2}|_{t=0} = \frac{1}{\lambda}$ ,  $E(X^2) = M_X^{(2)}(0) = \frac{2\lambda}{(\lambda-t)^3}|_{t=0} = \frac{2}{\lambda^2}$ .

Continuous dist.	pdf	mean	variance	mgf/moment
Uniform( $a, b$ )	$\frac{1}{b-a}$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$	$\frac{e^{tb}-e^{ta}}{t(b-a)}$
Exponential( $\theta$ )	$\frac{1}{\theta}e^{-\frac{x}{\theta}}$	$\theta$	$\theta^2$	$\frac{1}{1-\theta t}, t < \frac{1}{\theta}$
Exponential( $\lambda$ )	$\lambda e^{-\lambda x}$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$	$\frac{\lambda}{\lambda-t}, t < \lambda$
Normal( $\mu, \sigma^2$ )	$\frac{1}{\sqrt{2\pi\sigma^2}}e^{-\frac{(x-\mu)^2}{2\sigma^2}}$	$\mu$	$\sigma^2$	$e^{\mu t + \frac{\sigma^2 t^2}{2}}$
Gamma( $\alpha, \beta$ )	$\frac{1}{\Gamma(\alpha)\beta^\alpha}x^{\alpha-1}e^{-x/\beta}$	$\alpha\beta$	$\alpha\beta^2$	$\left(\frac{1}{1-\beta t}\right)^\alpha, t < \frac{1}{\beta}$
Beta( $\alpha, \beta$ )	$\frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)}x^{\alpha-1}(1-x)^{\beta-1}$	$\frac{\alpha}{\alpha+\beta}$	$\frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}$	$1 + \sum_{k=1}^{\infty} \left(\prod_{i=0}^{k-1} \frac{\alpha+i}{\alpha+\beta+i}\right) \frac{t^k}{k!}$
Cauchy	$1/(\pi(1+x^2)), x \in \mathbb{R}$	( $\infty$ )	n/a, $F_X(x)$	$= \arctan(x)/\pi + 1/2$
$\chi_p^2 = \sum_{i=1}^p Z_i^2$	$\frac{1}{2^{p/2}\Gamma(p/2)}x^{p/2-1}e^{-x/2}$	$p$	$2p$	$(1-2t)^{-p/2}, t < 1/2$

#### 4.不等式

Markov  $P(X \geq a) \leq \frac{E(X)}{a}, X \geq 0, a > 0$

Chebyshev  $P(|X - E(X)| \geq a) \leq \frac{V(X)}{a^2}$

Mill  $Z \sim N(0, 1)$ ,  $P(|Z| \geq t) \leq \frac{2}{\sqrt{2\pi}} \frac{e^{-t^2/2}}{t}$

Hoeffding :  $P(|X - \mu| \geq t) \leq 2 \exp\left(-\frac{2t^2}{\sum_{i=1}^n (b_i - a_i)^2}\right)$

$E(e^{\alpha X}) \leq \exp\left(\alpha^2 \frac{(b-a)^2}{8}\right), E(X) = 0, \alpha \in \mathbb{R}$

**例**  $X \sim \text{Bernoulli}(n, p)$ ,  $P(|\bar{X}_n - p| > \epsilon) \leq 2 \exp(-2n\epsilon^2)$

Cauchy-Schwartz  $E(XY) \leq \sqrt{E(X^2)E(Y^2)}$

Jensen  $E(g(X)) \geq g(E(X))$ ,  $g$  上凸.

#### 5.随机变量的收敛

概率  $X_n \xrightarrow{P} X : P(|X_n - X| \geq \epsilon) \rightarrow 0$ , as  $n \rightarrow \infty$ .

分布  $X_n \rightsquigarrow X : F_{X_n}(x) \rightarrow F_X(x), \forall x \in \text{连续点}$ .

均方  $X_n \xrightarrow{qm} X : E(X_n - X)^2 \rightarrow 0$ .

均方  $\rightarrow$  概率  $\xleftarrow{\text{单点}}$  分布.

依概率但不均方收敛  $X_n = \sqrt{n}I_{(0,1/n)}(U(0, 1)); 0$

依分布但不依概率收敛  $X \sim N(0, 1), X_n = -X$

1.  $X_n + Y_n \rightarrow X + Y : (P, qm)$  2.  $X_n Y_n \rightarrow XY : (P)$

3.  $g(X_n) \rightarrow g(X) : (P, \rightsquigarrow)$  4. (Slutzky)

$X_n \rightsquigarrow X, Y_n \rightsquigarrow c : X_n + Y_n \rightsquigarrow X + c, X_n Y_n \rightsquigarrow cX$ .

注: 通常  $X_n \rightsquigarrow X, Y_n \rightsquigarrow Y \nRightarrow X_n + Y_n \rightsquigarrow X + Y$ .

$\{X_i\}$  i.i.d.,  $\mu, \sigma^2$  存在,  $\bar{X}_N = \frac{1}{n} \sum_{i=1}^n X_i$

弱 LLN:  $\bar{X}_N \xrightarrow{P} \mu : \lim_{n \rightarrow \infty} P(|\bar{X}_n - \mu| \leq \epsilon) = 1$

强 LLN:  $\bar{X}_N \xrightarrow{a.s.} \mu : P(\lim_{n \rightarrow \infty} |\bar{X}_n - \mu| \leq \epsilon) = 1$

CLT:  $Z_n \equiv \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \rightsquigarrow N(0, 1)$ , i.e.,

$\lim_{n \rightarrow \infty} P(Z_n \leq z) = \Phi(z) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^z e^{-t^2/2} \, \mathrm{d}t$

变形:  $\bar{X}_n \approx N(\mu, \frac{\sigma^2}{n})$ ,  $\sqrt{n}(\bar{X}_n - \mu) \approx N(0, \sigma^2)$ .

样本  $S_n^2 = (n-1)^{-1} \sum (X_i - \bar{X}_n)^2$ , CLT  $\sigma$  换为  $S_n$ .

Delta 方法: 求极限分布

$Y_n \sim N(\mu, \frac{\sigma^2}{n}) \Rightarrow g(Y_n) \sim N(g(\mu), (g'(\mu))^2 \frac{\sigma^2}{n})$

#### 6.模型、统计推断与学习

参数模型:  $\mathcal{F} = \{f(x, \theta) : \theta \in \Theta\}$ , 如正态  $\theta = (\mu, \sigma)$

非参数模型: 无法用有限参数表示, 回归/聚类/决策树等

统计量: 完全基于样本所得的量, 是样本的函数.

点估计:  $\hat{\theta} = g(X_1, \dots, X_n)$ . 偏差  $\text{bias}(\hat{\theta}_n) = E_\theta(\hat{\theta}_n) - \theta$ .

无偏:  $\text{bias} = 0$ ; 相合:  $\hat{\theta}_n \xrightarrow{P} \theta$ .

标准误差  $\text{se}(\hat{\theta}_n) = \sqrt{V(\hat{\theta}_n)}$ ;

$\text{MSE} = E_\theta(\hat{\theta}_n - \theta)^2 = \text{bias}^2 + \text{se}^2$ .

如果  $\text{bias} \xrightarrow{P} 0$  且  $\text{se} \xrightarrow{P} 0$ , 则  $\hat{\theta}_n \xrightarrow{P} \theta$ .

渐进正态性:  $\frac{\hat{\theta}_n - \theta}{\text{se}} \rightsquigarrow N(0, 1)$ .

置信集: 置信区间  $C_n = (a_n, b_n)$ ,  $P_\theta(\theta \in C_n) = 1 - \alpha$ .

注: 置信区间是随机区间, 意思是给定若干组样本, 每组得到的置信区间覆盖真实参数的概率为  $1 - \alpha$ .

基于正态的置信区间:  $\hat{\theta}_n \pm z_{\alpha/2} \text{se}(\hat{\theta}_n)$ .

**例**  $\{X_n\} \sim \text{Bernoulli}(p)$ , 由 Chebyshev  $P(|\bar{X}_n - p| \geq \epsilon) \leq 2 \exp(-2n\epsilon^2)$ , 令  $\alpha = 2 \exp(-2n\epsilon) \Rightarrow \epsilon^2 = \log(2/\alpha)/(2n)$ , 因此  $C_n = (\bar{X}_n - \sqrt{\log(2/\alpha)/(2n)}, \bar{X}_n + \sqrt{\log(2/\alpha)/(2n)})$ ; 由渐进正态,  $C_n = (\bar{X}_n - z_{\alpha/2} \sqrt{\bar{X}_n(1 - \bar{X}_n)/n}, \bar{X}_n + z_{\alpha/2} \sqrt{\bar{X}_n(1 - \bar{X}_n)/n})$ .

$z_{\alpha/2} = \Phi^{-1}(1 - \alpha/2)$ .  $z_{0.05/2} = 1.96, z_{0.1/2} = 1.65, z_{0.025/2} = 2.24, z_{0.01/2} = 2.58, z_{0.005/2} = 2.80$ .

假设检验:  $H_0 : \theta \in \Theta_0, H_1 : \theta \in \Theta_1$ . 一般把可以否定, 且可根据其构建分布机制的命题作为原假设.

显著性水平: 小概率事件发生的概率  $\alpha$ ;

临界值:  $C$ , 使得  $P_\theta(\text{拒绝 } H_0, \text{如 } |\bar{X} - \mu| > C) = \alpha$ .

拒绝域:  $\mathcal{W}$ , 如  $\{(X_1, \dots, X_n) : |\bar{X} - \mu| > C\}$ .

## 7.CDF 和统计泛函的估计

经验分布函数  $F_n(x)=\frac{1}{n}\sum_{i=1}^nI(X_i\leq x)$  无偏,

$V(\hat{F}_n(x))=\frac{F(x)(1-F(x))}{n}\xrightarrow{P}0, F\in(0,1):\sqrt{n}(\hat{F}_n(x)-F(x))\rightsquigarrow N(0,F(x)(1-F(x)))$

统计泛函:  $T(F)$  是分布函数  $F$  的函数. 嵌入式估计量:  $\hat{\theta}_n=T(\hat{F}_n)$ . 线性泛函:  $T(F)=\int_{-\infty}^{+\infty}r(x)\,\mathrm{d}F(x)$ , 满足  $T(aF+bG)=aT(F)+bT(G)$ , 嵌入式估计量:  $T(\hat{F}_n)=\int_{-\infty}^{+\infty}r(x)\,\mathrm{d}\hat{F}_n(x)=\frac{1}{n}\sum_{i=1}^nr(X_i)$ ,

近似  $1-\alpha$  置信区间为  $T(\hat{F}_n)\pm z_{\alpha/2}\hat{\mathrm{s\acute{e}}}$ .

例  $\hat{\mu}=\overline{X}_n, \hat{\sigma}^2=\frac{1}{n}\sum_{i=1}^nX_i^2-\overline{X}_n^2$ .

## 8.Bootstrap 方法

从  $\hat{F}_n$  中生成  $X_1^*,\ldots,X_n^*$  计算统计量, 重复  $B$  次.

方差估计:  $V_{\mathrm{boot}}=\frac{1}{B}\sum_{b=1}^B(T_{n,b}^*-\overline{T}^*)^2$

正态区间法  $T_n\pm z_{\alpha/2}\sqrt{V_{\mathrm{boot}}}$ , 除非接近正态否则不准确.

枢轴量法: 定义  $R_n=\hat{\theta}-\theta, \hat{\theta}_{n^{1\dots B}}^*$  为副本,  $\theta_{\beta}^*$  为  $\beta$  分位数,

$C_n=(2\hat{\theta}_n-\theta_{1-\alpha/2}^*,2\hat{\theta}_n-\theta_{\alpha/2}^*)$

分位数置信区间:  $(\theta_{\alpha/2}^*,\theta_{1-\alpha/2}^*)$

## 9.参数推断

似然函数:  $\mathcal{L}_n(\theta)=\prod_{i=1}^nf(X_i,\theta)$ , 对数... $\ell_n(\theta)=\log L_n(\theta)$ , 极大似然估计 MLE  $\hat{\theta}_n$ : 使  $L_n(\theta)$  达到最大值的  $\theta$  的值, 可以解方程  $\partial\ell_n(\theta)/\partial\theta=0$  得到. Fisher 信息量  $I_n(\theta)=nI(\theta)=V_{\theta}(s(X;\theta))=\sum V_{\theta}(s(X_i;\theta))=E(s^2(X;\theta))=-E(\frac{\partial^2\ell(X;\theta)}{\partial\theta^2}), s(X;\theta)=\frac{\partial\log f(X;\theta)}{\partial\theta}$

渐进正态性: 令  $\mathrm{se}=\sqrt{V(\hat{\theta}_n)}$ , 适当正则条件下

1.  $\mathrm{se}\approx\sqrt{1/I_n(\theta)}, \frac{\hat{\theta}_n-\theta}{\mathrm{se}}\rightsquigarrow N(0,1)$ ,

2.  $\hat{\mathrm{s\acute{e}}}=\sqrt{1/I_n(\hat{\theta}_n)}, \frac{\hat{\theta}_n-\theta}{\mathrm{se}}\rightsquigarrow N(0,1)$

3.  $C_n=\hat{\theta}_n\pm z_{\alpha/2}\hat{\mathrm{s\acute{e}}}, P_{\theta}(\theta\in C_n)\rightarrow 1-\alpha$

MLE 相容性:  $\hat{\theta}_n\xrightarrow{P}\theta$ . KL 距离:  $D(P,Q)=\int p(x)\log\frac{p(x)}{q(x)}\,\mathrm{d}x, D(f,g)\geq 0, D(f,g)=0\Leftrightarrow f=g$ . 模型可识别:  $\theta\neq\phi\Rightarrow D(\theta,\phi)>0$  MLE 同变性:  $\tau=g(\theta), \hat{\tau}_n=g(\hat{\theta}_n)$

例  $N(\theta,\sigma^2), f(X;\theta)=\frac{1}{\sqrt{2\pi\sigma^2}}\exp\left(-\frac{(X-\theta)^2}{2\sigma^2}\right)$ , 记分函数  $s(X;\theta)=$

$\frac{\partial\log f(X;\theta)}{\partial\theta}=\frac{X-\theta}{\sigma^2}, I_n(\theta)=-E(\frac{\partial^2\ell(\theta)}{\partial\theta^2})=-nE_{\theta}(-\frac{1}{\sigma^2})=\frac{n}{\sigma^2},$

$\hat{\mathrm{s\acute{e}}}=\sqrt{\frac{\sigma^2}{n}}$ , 故  $\overline{X}$  近似服从  $N(\theta,\sigma^2/n)$ .

例 1. 正态分布  $\hat{\mu}=\overline{X}, \hat{\sigma}=S$ ; 2.  $\{X_i\}\sim U(0,\theta)$  i.i.d.,  $f(x;\theta)=1/\theta$  if  $0\leq x\leq\theta, \mathcal{L}_n(\theta)=(1/\theta)^n$  if  $\theta\geq\max\{X_i\}$ , 因此  $\hat{\theta}_n=\max\{X_i\}$  3.  $f(x)=\theta x^{\theta-1}$  求  $\hat{\theta}, \ell_n(\theta)=n\log\theta+(\theta-1)\sum\log X_i$ , 解方程  $\partial\ell_n(\theta)/\partial\theta=0$  得到  $\hat{\theta}_n=-\frac{n}{\sum\log X_i}$ .

例 证明  $E((\frac{\partial\log f(x_i;\theta)}{\partial\theta})^2)=-E_{\theta}(\frac{\partial^2\log f(x_i;\theta)}{\partial\theta^2})$ . 记  $\ell'=\frac{\partial\log f(x_i;\theta)}{\partial\theta}, \ell''=\frac{\partial^2\log f(x_i;\theta)}{\partial\theta^2}$ , 则  $\ell'=\frac{f'}{f(x_i;\theta)}, \ell''=\frac{f''-f'^2}{f(x_i;\theta)}$ , 即证  $\int f''\,\mathrm{d}x=0. \int f''\,\mathrm{d}x=\frac{\partial}{\partial\theta}\int f'\,\mathrm{d}x=\frac{\partial}{\partial\theta}(f(+\infty)-f(-\infty))$  由  $f(+\infty)=f(-\infty)=0$  得证.

MLE Delta 方法:  $\tau=g(\theta), g'(\theta)\neq 0$ , 则  $\frac{\hat{\tau}_n-\tau}{\hat{\mathrm{s\acute{e}}}(\hat{\tau}_n)}\rightsquigarrow Z$ ,

$\hat{\tau}_n=g(\hat{\theta}_n)$ , 且  $\hat{\mathrm{s\acute{e}}}(\hat{\tau}_n)=\sqrt{V(\hat{\tau}_n)}=|g'(\hat{\theta}_n)|\hat{\mathrm{s\acute{e}}}(\hat{\theta}_n)$ .

例 Poisson( $\lambda$ ), 矩估计:  $\hat{\lambda}=\overline{X}_n, f(X;\lambda)=\frac{\lambda^X}{X!}e^{-\lambda}, \mathcal{L}_n=\prod\frac{\lambda^{X_i}e^{-\lambda}}{(X_i)!}, \ell_n=\sum(X_i\log\lambda-\lambda-\log(X_i)!), \partial=0$  得  $\overline{X}$ .  $s(X;\lambda)=\frac{\partial\log f(X;\lambda)}{\partial\lambda}=\frac{X-\lambda}{\lambda}, I_n(\lambda)=nI(\lambda)=nE(s^2(X;\lambda))=\frac{n}{\lambda}, \hat{\mathrm{s\acute{e}}}=\sqrt{\frac{\hat{\lambda}}{n}}$ ,  $\overline{X}$  近似服从  $N(\lambda,\lambda/n)$ ,  $1-\alpha$  置信区间为  $\hat{\lambda}\pm z_{\alpha/2}\sqrt{\frac{\hat{\lambda}}{n}}$ .

例  $N(\theta,1), Y_i=I(X_i>0), \psi=P(Y_1=1). \mathcal{L}_n(\theta)=\prod\frac{1}{\sqrt{2\pi}}e^{-\frac{(X_i-\theta)^2}{2}}, \ell_n(\theta)=-\frac{n}{2}\log 2\pi-\frac{1}{2}\sum(X_i-\theta)^2, \partial\ell_n(\theta)/\partial\theta=\sum(x_i-\theta), =0:\hat{\theta}=\overline{X}. I_n(\theta)=nE_{\theta}(s^2(X_i;\theta))=n, \hat{\mathrm{s\acute{e}}}(\hat{\theta})=\frac{1}{\sqrt{I_n(\theta)}}=\frac{1}{\sqrt{n}}, \psi=\Phi(\theta), \hat{\psi}=\Phi(\hat{\theta})=\Phi(\overline{X}), \hat{\mathrm{s\acute{e}}}(\hat{\psi})=|\Phi'(\hat{\theta})|\hat{\mathrm{s\acute{e}}}(\hat{\theta})=\phi(\hat{\theta})\hat{\mathrm{s\acute{e}}}(\hat{\theta}). \hat{\psi}=1/n\sum Y=E[\overline{Y}]\xrightarrow{P}E[Y]=\psi, 渐进效率 V(\hat{\tilde{\psi}})/V(\hat{\psi})=\psi(1-\psi)/\phi(\theta)=\Phi(\theta)(1-\Phi(\theta))/\phi(\theta). 非正态: 由 LLN  $\hat{\psi}\xrightarrow{P}\Phi(\mu), F_X(0)\neq 1-\Phi(\mu)$  都不相合.$

例  $X_1\sim\mathrm{Binomial}(n_1,p_1), X_2\sim\mathrm{Binomial}(n_2,p_2), \psi=p_1-p_2, f(X_i;p_i)=\binom{n_i}{X_i}p_i^{X_i}(1-p_i)^{n_i-X_i}, \frac{\partial}{\partial p_i}s(X_i;p_i)=\frac{X_i}{p_i}+\frac{X_i}{1-p_i}=\frac{X_i-np_i}{p_i(1-p_i)} \hat{p}_i=X_i/n_i, \hat{\psi}=\hat{p}_1-\hat{p}_2=X_1/n_1-X_2/n_2.$

$I(p_1,p_2)=(\partial^2\log f((X_1,X_2);p)/\partial p_1\partial p_j)=\begin{bmatrix} \frac{n_1}{p_1(1-p_1)} & 0 \\ 0 & \frac{n_2}{p_2(1-p_2)} \end{bmatrix}.$

多参:  $\theta=(\theta_1,\ldots,\theta_k)^T$  Fisher 信息矩阵  $I_n(\theta)=(E_{\theta}(H_{ij}))$ ,  $H_{ij}=\frac{\partial\log f(X;\theta)}{\partial\theta_i\partial\theta_j}, J_n(\theta)=I_n^{-1}(\theta)$

多参数 Delta 方法:  $\nabla g=(\frac{\partial g}{\partial\theta_1},\ldots)^T$  在  $\hat{\theta}_n$  处不为 0, 令  $\hat{\tau}_n=g(\hat{\theta}_n)$ , 则  $\frac{\hat{\tau}_n-\tau}{\sqrt{\hat{\tau}_n^TJ_n(\hat{\theta}_n)\hat{\tau}_n}}\rightsquigarrow N(0,1)$ , 其中  $\hat{\mathrm{s\acute{e}}}(\hat{\tau}_n)=\sqrt{(\nabla g|_{\theta=\hat{\theta}_n})^TJ_n(\hat{\theta}_n)(\nabla g|_{\theta=\hat{\theta}_n})}$ .

例  $X_1\ldots X_n\sim N(\mu,\sigma^2), \psi=g(\mu,\sigma)=\sigma/\mu, (\mu,\sigma^2)$  MLE:  $(\overline{X},S^2), I_n(\mu,\sigma^2)=\begin{pmatrix} n/\sigma^2 & 0 \\ 0 & 2n/\sigma^2 \end{pmatrix}J_n=\begin{pmatrix} \sigma^2/n & 0 \\ 0 & \sigma^2/2n \end{pmatrix},$

$\nabla g=(-\frac{\sigma}{\mu^2},\frac{1}{\mu})^T, \hat{\mathrm{s\acute{e}}}(\hat{\tau})=\frac{1}{\sqrt{n}}\sqrt{\frac{\hat{\sigma}^4}{\hat{\mu}^4}+\frac{\sigma^2}{2\hat{\mu}^2}}.$

## 10.假设检验与 p 值

检验统计量:  $T_n=T(X_1,\ldots,X_n)$ ,

拒绝域  $\mathcal{A}=\{T_n>c\}$ ,  $c$  为临界值.

第一类错误: 假阳性; 第二类错误: 假阴性.

势函数  $\beta(\theta)=P_{\theta}(X\in\mathcal{A})$ , 容量  $\beta=\sup_{\theta\in\Theta_1}\beta(\theta)$

容量  $\leq\alpha$  称检验水平为  $\alpha$ . 简单  $\theta=\theta_0$  复合  $\theta\geq\theta_0$

双边  $H_0:\theta=\theta_0$  vs ... 单边  $H_0:\theta\geq\theta_0$  vs ...

例  $X_1\ldots X_n\sim N(\mu,\sigma^2)$ , 检验  $H_0:\mu=\mu_0$  vs  $H_1:\mu\neq\mu_0$ , 检验统计量  $T_n=\sqrt{n}\frac{|\overline{X}_n-\mu_0|}{S_n}$ , 拒绝域  $\{T_n>z_{\alpha/2}\}$ , 势函数  $\beta(\mu)=P_{\mu}(T_n>z_{\alpha/2})$

如检验  $H_0:\mu\leq 0$  vs  $H_1:\mu>0$ , 拒绝域  $\mathcal{A}=\{\overline{X}>c\}$ , 势函数  $\beta(\mu)=P_{\mu}(\overline{X}>c)=P(\sqrt{n}\frac{(\overline{X}-\mu)}{\sigma}>\sqrt{n}\frac{c-\mu}{\sigma})=1-\Phi(\sqrt{n}\frac{c-\mu}{\sigma})$ , 检验水平  $\alpha=\sup_{\mu\leq\mu_0}\beta(\mu)=1-\Phi(\sqrt{n}\frac{c-\mu_0}{\sigma})$ , 设定显著性水平  $\alpha, c=\mu_0+\frac{\sigma}{\sqrt{n}}z_{\alpha/2}$ .

Wald 检验:  $H_0:\theta=\theta_0$  vs  $H_1:\theta\neq\theta_0$ , 若  $\hat{\theta}$  渐进正态,  $W=\frac{\hat{\theta}-\theta_0}{\hat{\mathrm{s\acute{e}}}(\hat{\theta})}$ , 当  $|W|>z_{\alpha/2}$  时拒绝  $H_0$ . 势函数:

$\beta(\theta_*)\approx 1-\Phi(z_{\alpha/2}+\frac{\theta_0-\theta_*}{\hat{\mathrm{s\acute{e}}}(\hat{\theta})})+\Phi(-z_{\alpha/2}+\frac{\theta_0-\theta_*}{\hat{\mathrm{s\acute{e}}}(\hat{\theta})})$

Wald 置信区间:  $C=(\hat{\theta}-z_{\alpha/2}\hat{\mathrm{s\acute{e}}}(\hat{\theta}),\hat{\theta}+z_{\alpha/2}\hat{\mathrm{s\acute{e}}}(\hat{\theta}))$ ,

p 值:  $\inf\{\alpha:\theta_0\in C\}$ , 拒绝  $H_0$  的最小检验水平, 拒绝的强弱

例 给定样本  $\{X_m\},\{Y_n\}$ , 检验均值是否相等.

$H_0:\mu_X-\mu_Y=0$  vs  $H_1:\mu_X-\mu_Y\neq 0$ ,

$V(\hat{\theta})=V(\overline{X}-\overline{Y})=\frac{\sigma_X^2}{m}+\frac{\sigma_Y^2}{n}, \hat{\mathrm{s\acute{e}}}=\sqrt{\frac{S_X^2}{m}+\frac{S_Y^2}{n}},$

拒绝域为  $|\overline{X}-\overline{Y}|>z_{\alpha/2}\hat{\mathrm{s\acute{e}}}$ ,

例: 给定样本  $\{(X_n,Y_n)\}$  配对检验均值是否相等.

$H_0:\mu_X=\mu_Y$  vs  $H_1:\mu_X\neq\mu_Y$ , 构造  $\theta=\mu_1-\mu_2$ , 估计为  $\hat{\theta}=\overline{X}-\overline{Y}$ . 方差:  $V(\hat{\theta})=\sigma^2/n$ , 其中  $\sigma$  是总体标准差, 用样本估计  $\hat{\mathrm{s\acute{e}}}=\sqrt{S^2/n}$ , 拒绝域为  $|\overline{X}-\overline{Y}|>z_{\alpha/2}\hat{\mathrm{s\acute{e}}}$ .

例 计算出了  $W=\left|\frac{\overline{X}-\overline{Y}}{\hat{\mathrm{s\acute{e}}}}\right|$ , p 值:  $P(|Z|>W)_{(Z\sim N(0,1))}$

Pearson  $\chi^2$  统计量:  $X=(X_1,\ldots,X_k)$  服从多项分布  $M(n,p=(p_1,\ldots,p_k))$ , 检验  $H_0/1:p? =p_0$ .

检验统计量  $T=\sum_{i=1}^k\frac{(X_i-np_{0i})^2}{np_{0i}}=\sum_{i=1}^k\frac{(X_i-E(X_i))^2}{E(X_i)}$ , 拒绝域为  $T>\chi_{k-1}^2(\alpha)$ , p 值为  $P(\chi^2(k-1)>T)$ .

置换检验: 检验分布是否相同, shuffle 看统计量分位数

似然比检验:  $H_0:\theta\in\Theta_0$  vs  $H_1:\theta\notin\Theta_0$ ,

$\lambda=2\log\left(\frac{L(\hat{\theta})}{L(\hat{\theta}_0)}\right), \hat{\theta}_0$  表示限制  $\Theta_0. \lambda\rightsquigarrow\chi_{\dim\Theta-\dim\Theta_0}^2$ ,

p 值  $P(\chi^2(\ldots)>\lambda)$ .

例 豌豆实验自由度为 3-0 而非 4, 因为概率和为 1.

例 Poisson( $\lambda$ ),  $H_0:\lambda=\lambda_0$  vs  $\neq. \hat{\lambda}=\sum X_n/n, V\left(\hat{\lambda}\right)=$

$\lambda/n, \mathrm{se}(\hat{\lambda})=\sqrt{\lambda/n}, W=\sqrt{n}\frac{\hat{\lambda}-\lambda_0}{\sqrt{\lambda_0}}, \mathcal{A}=\{|W|>z_{\alpha/2}\}$

例  $N(\theta,1), H_0:\theta=0$  vs  $H_1:\theta=1$ . 拒绝域  $\{\overline{X}>c\}$ , 显著性水平  $\alpha, \frac{\overline{X}-\theta}{\sqrt{1/n}}\sim N(0,1)\Rightarrow P\left(\frac{T(x^n)-0}{\sqrt{1/n}}>\frac{c-0}{\sqrt{1/n}}\right)=1-\Phi(c\sqrt{n}), c=\Phi^{-1}(1-\alpha/2)/\sqrt{n}, \beta(\theta)=P(\frac{T(x^n)-\theta}{\sqrt{1/n}}>\frac{c-\theta}{\sqrt{1/n}})=1-\Phi((c-\theta)\sqrt{n})$   $H_1$  下势函数  $\beta(1)=1-\Phi((c-1)\sqrt{n})$ .

例  $N(\mu,\sigma^2), H_0:\mu=\mu_0$  vs  $\neq$ . 似然比检验  $\ell_n(\mu,\sigma)=-n\log\sigma-\frac{1}{2\sigma^2}\sum_i(X_i-\mu)^2+C, \lambda=2\ell(\hat{\mu},\sigma)-2\ell(\mu_0,\sigma)=\frac{1}{\sigma^2}\left(n(\mu_0^2-\hat{\mu}^2)-2(\mu_0-\hat{\mu})\cdot n\hat{\mu}\right)=\frac{n(\hat{\mu}-\mu_0)^2}{\sigma^2},$  Wald  $W=\sqrt{n}\frac{\hat{\mu}-\mu_0}{\sigma}, \lambda=\sqrt{W}$ . 检验  $H_1:\sigma=\sigma_0$  vs  $\neq$ ,  $\lambda=2\ell(\mu,\hat{\sigma})-2\ell(\mu,\sigma_0)=2n(\log\sigma_0-\log\hat{\sigma})+\frac{n(\hat{\sigma}^2-\sigma_0^2)}{\sigma_0^2},$

Wald  $W=\sqrt{n}\frac{\hat{\sigma}-\sigma_0}{\sqrt{1/I(\hat{\sigma})}}=\sqrt{2n}\frac{\hat{\sigma}-\sigma_0}{\hat{\sigma}}$  例 Binomial( $n,p$ ),

$H_0:p=p_0$  vs  $\neq$ , 令  $X=\sum X_i, \mathcal{L}(p)=\binom{n}{X}p^X(1-p)^{n-X}, \ell(p)=\log\left(\binom{n}{X}\right)+X\log p+(n-X)\log(1-p), \lambda=2\ell\hat{p}-2\ell p_0=2X(\log\hat{p}-\log p_0)+2(n-X)(\log(1-\hat{p})-\log(1-p_0))$  Wald  $W=\sqrt{n}\frac{\hat{p}-p_0}{\sqrt{\hat{p}(1-\hat{p})}}$

多重假设检验: Bonferroni:  $\alpha/m$  (Union bound).

BH(FDR): 排序后  $p_i\leq\frac{i\alpha}{mC_m}, C_m$  不独立  $\sum_{i=1}^m\frac{1}{i}$ , 独立 1. 例 检验药品比较安慰剂. 设  $X_i\sim\mathrm{Binomial}(n_i,q_i)$  表示恶心数量,  $H_{0i}:q_0=q_i. \hat{q}_i=x_i/n_i, \hat{\theta}_i=q_0-q_i, \mathrm{se}(\hat{\theta}_i)=\sqrt{\frac{\hat{q}_0(1-\hat{q}_0)}{n_0}+\frac{\hat{q}_i(1-\hat{q}_i)}{n_i}}, W_i=\frac{\hat{\theta}_i}{\mathrm{se}(\hat{\theta}_i)}, p$  值足够小且检验量为正才有效. 若多重检验: 1. Bonferroni:  $W_i>z_{\alpha/2m}$ ; 2. BH:  $p$  值排序后与  $i\alpha/m$  比较.

例 袋子摸红蓝球,  $H_0:p=0.5$  vs  $H_1:p=0.7, X_i=I(i\text{蓝})$  六次抽样  $Y=\sum_{i=1}^6X_i\sim\mathrm{binom}(6,p), Y$  的 pmf  $f(y|p)=\binom{6}{y}p^y(1-p)^{6-y}$ , 基于  $H_0$  和  $H_1$  的似然比为  $\Lambda(y)=\frac{f(y|0.7)}{f(y|0.5)}=\frac{0.7^y0.3^{6-y}}{0.5^y0.5^{6-y}}=1.4^y0.3^6$ , 结果如表

$y$	0	1	2	3	4	5	6
$f(y 0.5)$	0.016	0.094	0.234	0.312	0.234	0.094	0.016
$f(y 0.7)$	0.001	0.010	0.060	0.185	0.324	0.303	0.117
$\Lambda(y)$	16.0	9.4	3.9	1.686	0.722	0.310	0.136

$\Lambda(0)=16$  vs  $\Lambda(6)=0.136$ , 因此小的  $\Lambda$  拒绝  $H_0$ , 拒绝域为  $C=\{y|\Lambda(y)\leq k(\alpha)\}$ . 此处  $k(0.016)=0.136, k(0.11=0.094+0.016)=0.310$ .

## 13.线性回归和 Logistic 回归

线性:  $Y=\beta_0+\beta_1X+\epsilon, \epsilon:E=0, V=\sigma^2, \hat{y}_i=\hat{\beta}_0+\hat{\beta}_1x, \hat{\epsilon}=y_i-\hat{y}_i$ . 最小二乘: 使  $\mathrm{RSS}=\sum\epsilon_i^2$  最小,  $E(\mathrm{RSS})=(n-2)\sigma^2$

$\ell_{xy}=\sum(x_i-\overline{x})(y_i-\overline{y})=\sum x_iy_i-n\overline{x}\overline{y}, \ell_{xx}=\sum(x_i-\overline{x})^2=\sum x_i^2-n\overline{x}^2, \hat{\beta}_1=\ell_{xy}/\ell_{xx}, \hat{\beta}_0=\overline{y}-\hat{\beta}_1\overline{x}, \hat{\sigma}^2$  无偏估计为  $\frac{1}{n-2}\mathrm{RSS}$ .

正态性假设下, 最小二乘即极大似然. 若  $\epsilon_i|x_i\sim N(0,\sigma^2)$ , 则  $L(\beta_0,\beta_1,\sigma^2)\propto\sigma^{-n}\exp\left(-\frac{1}{2\sigma^2}\sum(y_i-\beta_0-\beta_1x_i)^2\right). t(\beta_0,\beta_1,\sigma^2)\propto -n\log\sigma-\frac{1}{2\sigma^2}\sum(y_i-\beta_0-\beta_1x_i)^2. \hat{\sigma}^2=1/n\sum\hat{\epsilon}_i^2. \hat{\mathrm{s\acute{e}}}(\hat{\beta}_1)=\sqrt{\frac{\hat{\sigma}^2}{\ell_{xx}}}, \hat{\mathrm{s\acute{e}}}(\hat{\beta}_0)=\hat{\mathrm{s\acute{e}}}(\hat{\beta}_1)\sqrt{\frac{1}{n}\sum x_i^2}$ , 适当条件下, 相合, 渐进正态  $(\frac{\hat{\beta}_1-\beta_1}{\hat{\mathrm{s\acute{e}}}(\hat{\beta}_1)})\rightsquigarrow N(0,1)$ , 渐进置信  $\hat{\beta}_1\pm z_{\alpha/2}\hat{\mathrm{s\acute{e}}}(\hat{\beta}_1)$ ,

$W=\hat{\beta}_1/\hat{\mathrm{s\acute{e}}}(\hat{\beta}_1)$ . 近似预测:  $\hat{\xi}_n^2=\hat{\sigma}^2\left(\frac{1}{n}+(\frac{x_0-\overline{x}}{\ell_{xx}})\right). \hat{y}_* \pm z_{\alpha/2}\hat{\xi}_n$ .

Logistic 回归: 分类损失函数不连续, 换 Sigmoid (Logistic)  $g(x)=\frac{1}{1+e^{-x}}, Y_i\in\{0,1\}\sim\mathrm{Bern}(r(X_i))$

$r(X)=P(Y_i=1|X=x)\frac{1}{1+e^{-X^T\beta}}=\frac{e^{X^T\beta}}{1+e^{X^T\beta}}. \hat{\beta}=\argmax_{\beta}L(\beta)=\prod_{i=1}^r(X_i)^{Y_i}(1-r(X_i))^{1-Y_i}=\prod_{i=1}^ne^{\frac{Y_iX_i^T\beta}{1+e^{X_i^T\beta}}}$ , 无显式解, 牛顿迭代;  $\nabla L(\beta)=\sum_{i=1}^n[y_i\mathbf{x}_i-p_i\mathbf{x}_i]=X^T(Y-p)$   $H(\beta)=-\sum_{i=1}^np_i(1-p_i)\mathbf{x}_i\mathbf{x}_i^T=-X^TWX. P$  是  $n\times 1$  的概率向量, 其元素为  $p_i=e^{X_i^T\beta}/\left(1+e^{X_i^T\beta}\right)$  是  $P(y_i=1)$ .  $W$  是对角阵, 对角线元素为  $p_i(1-p_i)$ . 迭代公式:  $\beta^{(j+1)}=\beta^{(j)}-(X^TWX)^{-1}X^T(Y-p)$ ;

线性回归: 最大似然函数:  $\sigma$  的分布函数 (把  $\sigma$  换成  $Y-X^T\beta$ ).  $\sigma$  服从椭圆分布时,  $\frac{\partial\mathrm{RSS}}{\partial\beta}=-2X^T(Y-X\beta)$ , 显式解  $\hat{\beta}=(X^TX)^{-1}X^TY$ .

例 给定  $(y_i,x_i)$ , 判断  $\beta$  MLE 是否有显式解, 如无给出迭代更新式, 写成加权最小二乘. (1)  $Y=X\beta+\epsilon, f(\epsilon)\propto g(\epsilon^T\epsilon)$ . (2)  $\mathrm{logit}(E(y_i|x_i))=\mathbf{x}_i^T\beta$ . (1)  $\mathcal{L}(X_i,Y_i,\beta)=f(Y-X\beta)\propto g((Y-X\beta)^T(Y-X\beta))$ ,  $\hat{\beta}=\argmax_{\beta}g((Y-X\beta)^T(Y-X\beta)), \frac{\partial\ell}{\partial\beta}=g'((Y-X\beta)^T(Y-X\beta))\cdot 2(X^TX\beta-X^TY), \hat{\beta}=(X^TX)^{-1}X^TY$ .

(2)  $E(y_i|\mathbf{x}_i)=P(y_i=1\mathbf{x})=p_i$ ,  $y_i$  是服从  $p_i$  的 Bernoulli 分布.  $L(X,Y,\beta)=\prod[p_i]^{y_i}[1-p_i]^{1-y_i}, \ell=\sum y_i\log p_i+(1-y_i)\log(1-p_i)=\sum(y_i\log\frac{p_i}{1-p_i}+\log(1-p_i))$ , 由于  $p_i=E(y_i|\mathbf{x}_i)$ ,  $\mathrm{logit}(E(y_i|\mathbf{x}_i))=\log\frac{p_i}{1-p_i}=\mathbf{x}_i^T\beta$  原式  $=\sum(y_i\mathbf{x}_i^T\beta-\log(1+e^{\mathbf{x}_i^T\beta}))$ ,  $\partial\ell/\partial\beta=\sum(y_i-\frac{e^{\mathbf{x}_i^T\beta}}{1+e^{\mathbf{x}_i^T\beta}})\mathbf{x}_i=\sum(y_i-p_i)\mathbf{x}_i$ ,

没有解析解, 牛顿迭代  $\beta^{(t+1)}=\beta^{(t)}-\left(\frac{\partial^2\ell}{\partial\beta^2}\right)^{-1}\frac{\partial\ell}{\partial\beta}=\beta^{(t)}+[\sum\frac{\exp(\mathbf{x}_i^T\beta^{(t)})}{(1+\exp(\mathbf{x}_i^T\beta^{(t)}))^2}\mathbf{x}_i\mathbf{x}_i^T]^{-1}[\sum(y_i-p_i)\mathbf{x}_i]$ .

写成加权最小二乘: 令  $s=0$  并循环迭代: 1. 令  $Z=(Z_1,Z_2,\ldots,Z_n)^T$ , 这里  $Z_i=\log\left(\frac{p_i^{(s)}}{1-p_i^{(s)}}\right)+\frac{y_i-p_i^{(s)}}{p_i^{(s)}(1-p_i^{(s)})}$ ; 2. 令  $W=\mathrm{diag}(\mathbf{w}_i^{(s)})$ , 这里  $\mathbf{w}_i^{(s)}=p_i^{(s)}(1-p_i^{(s)})$ ; 3.  $\hat{\beta}^{(s+1)}=(X^TWX)^{-1}X^TWZ$ .